CIA6041 | Inteligencia Artificial y Gestión de Datos Organizacionales

SEM10 - TAREA DE ASIGNACIÓN #10

Nombre de la actividad**:** Proyecto final y defensa del caso de estudio.

Caso: Nómina Inteligente (predicción y segmentación de empleados)

Profesor: Jhony Andrés Guzmán Henao

Integrantes: Jesús Jaquez González · Libia Ortiz Bedoya · Sergio Rivera · Roberto Armuelles

Informe Técnico — Nómina Inteligente

Advanced Tech Group | CIA6041 | Proyecto final y defensa del caso de estudio

1. El problema organizacional

Advanced Tech Group, empresa ficticia del sector tecnológico, gestiona la nómina de forma manual, sin poder anticipar el costo mensual ni detectar a tiempo a los empleados con mayor riesgo de renuncia. La ausencia de un sistema de alerta temprana impide que Recursos Humanos actúe antes de que ocurra la salida de un empleado, lo que se traduce en costos de reemplazo, pérdida de conocimiento institucional y una planificación financiera reactiva en vez de anticipada.

Pregunta de negocio: ¿qué empleados tienen mayor riesgo de renunciar, y qué factores (salario, horas extra, antigüedad) influyen más en esa decisión? El proyecto está dirigido al equipo de Recursos Humanos y a la dirección financiera de la organización, como usuarios finales de sus hallazgos y su dashboard.

2. Los datos y el proceso ETL

Se utilizó el IBM HR Analytics Employee Attrition & Performance Dataset (Kaggle, licencia DbCL v1.0) [1] , un dataset público y ficticio con 1,470 registros y 35 variables originales, elegido por: contener variables directamente relacionadas con nómina, desempeño y rotación; estar limpio y bien documentado; y no representar ningún riesgo de privacidad al ser sintético.

Auditoría de calidad

Se verificó, con tres métodos independientes (Excel, fórmulas automatizadas y Python), que el dataset no contiene valores vacíos ni filas duplicadas en ninguna de sus 1,470 observaciones.

Limpieza

- Se eliminaron 3 columnas constantes sin valor analítico: EmployeeCount, Over18, StandardHours (mismo valor en las 1,470 filas).
- EmployeeNumber se mantuvo como llave primaria (identificador único), pero se excluyó como variable predictora — una prueba de fuga de datos confirmó que incluirlo altera las métricas del modelo sin mejorar su capacidad real de generalización.

Columnas derivadas

- Banda salarial (Bajo/Medio/Alto, según MonthlyIncome) y Grupo de antigüedad (Nuevo/Intermedio/Senior, según YearsAtCompany), creadas para simplificar el análisis sin fabricar información inexistente.

Resultado: dataset_nomina_limpio.csv — 35 columnas, 1,470 filas, reproducible tanto en Power Query como en Python (ambos caminos producen el mismo archivo final).

3. Análisis exploratorio de datos (EDA)

El análisis exploratorio, realizado en Power BI (Key Influencers) y confirmado con código en Python, identificó que las horas extra (OverTime = Yes) multiplican por 2.93 veces la probabilidad de que un empleado renuncie — el hallazgo más importante del proyecto.

- Costo total de nómina: $9,559,309/mes | Salario promedio: $6,502.93
- Tasa de rotación general: 16.12% (237 de 1,470 empleados)
- El salario crece con la antigüedad en los tres departamentos, con una correlación positiva moderada (r entre 0.49 y 0.60)

Las visualizaciones exploratorias (dispersión de salario vs. antigüedad, barras de salario promedio por grupo) se replicaron de forma idéntica en Power BI, Tableau y Python, confirmando la consistencia de los hallazgos entre herramientas.

4. Modelos de machine learning

Modelo supervisado — árbol de decisión (predice Attrition)

Siguiendo la guía de laboratorio de la Semana 8 [5], se entrenó un árbol de decisión (profundidad máxima 5, balanceado por clase) para predecir la renuncia, comparado siempre contra una línea base: predecir siempre "No renuncia" acertaría el 83.90% de las veces, dado el desbalance de clases (16.1% de renuncias reales).

Métrica	Línea base	Modelo (árbol)
Exactitud	83.90%	73.24%
Precisión (Yes)	—	32.06%
Sensibilidad (Yes)	—	59.15%
F1 (Yes)	—	41.58%

La exactitud del modelo queda por debajo de la línea base — un resultado esperado y explicado: el modelo sacrifica exactitud general para detectar mejor los casos de renuncia real (59.15% de sensibilidad), que es lo que importa para el negocio. De los 71 empleados que renunciaron en el conjunto de prueba, el modelo detectó 42 y no detectó 29 (41% de falsos negativos).

Una prueba adicional confirmó fuga de datos al incluir EmployeeNumber: la exactitud sube artificialmente de 73.24% a 73.92%, y el identificador obtiene una importancia real (0.050, puesto 8 de 50 variables) pese a no representar ninguna característica del empleado.

Modelo no supervisado — K-Means (segmentación)

Se segmentó a los 1,470 empleados en 3 grupos según salario y antigüedad, con el número de grupos justificado mediante el método del codo. El índice de silueta [4] obtenido fue 0.623 (grupos razonablemente

separados), sin ningún empleado con coeficiente negativo, aunque el 5% (73 empleados) se ubica cerca de la frontera entre segmentos.

- Segmento junior (916 empleados): salario ~$3,600, antigüedad ~5 años
- Segmento medio (365 empleados): salario ~$8,500, antigüedad ~8 años
- Segmento senior (189 empleados): salario ~$16,700, antigüedad ~14 años

5. Hallazgos, recomendaciones y limitaciones

Hallazgo principal

Las horas extra son el factor más asociado al riesgo de renuncia según Key Influencers (2.93x), por encima de tener 1 año o menos de antigüedad (2.70x), un salario mensual bajo (2.60x) y un balance vida-trabajo bajo (2.05x). El efecto se mantiene dentro de cada segmento: la tasa de renuncia pasa de 12.3% a 38.3% en el segmento junior, de 9.9% a 21.6% en el medio y de 2.3% a 12.1% en el senior.

Recomendación

Priorizar la revisión de la carga de horas extra, comenzando por el segmento junior, donde se concentra el 75% de las renuncias (179 de 237; tasa de 19.5%) y, dentro de él, quienes hacen horas extra (38.3% de renuncia frente a 12.3% de quienes no las hacen). El segmento medio tiene una tasa de 13.2% (48 renuncias) y el senior de 5.3% (10 renuncias); para este último se sugiere seguimiento individual y no un programa masivo. Un costo de reemplazo mayor en el segmento senior es una suposición razonable, pero el dataset no incluye costos de reemplazo y no permite verificarla.

Limitaciones

- El árbol de decisión no fue optimizado con validación cruzada ni ajuste de hiperparámetros; es un punto de partida, no un modelo final.
- El número de segmentos (k=3) se apoya en el método del codo y en criterio de negocio, no en un óptimo matemático único.
- El dataset es sintético y es un corte transversal, sin componente temporal — no permite validar el modelo contra renuncias reales ni medir rotación interna a lo largo del tiempo.
- Por estas razones, no se recomienda desplegar estos modelos en producción sin las mejoras señaladas: validación cruzada, ajuste del umbral de decisión según el costo real de cada tipo de error, monitoreo continuo y, sobre todo, validación con datos reales de una organización.

6. Reflexión ética sobre el uso de los datos y de la IA

El uso de un dataset ficticio eliminó cualquier riesgo real de privacidad durante el desarrollo del proyecto. Sin embargo, el equipo aplicó los mismos principios que exigiría un caso real: se decidió no incluir un segmentador por género en el dashboard, pese a que la variable está disponible, al no encontrar

un propósito de negocio claro para filtrar por esa dimensión — priorizando el criterio ético sobre la conveniencia técnica.

El modelo predictivo está diseñado para señalar riesgo, no para decidir: la responsabilidad de actuar sobre una alerta de renuncia sigue siendo de una persona de Recursos Humanos, no del algoritmo. Se priorizó además la explicabilidad sobre la complejidad — Key Influencers y un árbol de decisión de profundidad limitada permiten entender por qué el modelo llega a una conclusión, en vez de operar como una caja negra.

Si este proyecto se implementara con datos reales de una organización, sería necesario incorporar anonimización, cumplir principios de privacidad aplicables (como el RGPD [2] o la Ley 1581 de Colombia [3]), y validar los hallazgos con supervisión humana antes de usarlos en decisiones que afecten a personas concretas.

7. Declaración de uso de herramientas de IA

El equipo utilizó asistencia de inteligencia artificial (Claude, de Anthropic) a lo largo del proyecto para organizar documentos, estructurar código, redactar guiones y sintetizar hallazgos — declarado explícitamente en ambos Video Foro del curso. Todo el contenido generado fue revisado y verificado por el equipo contra los datos reales antes de incorporarlo a cualquier entregable; varios errores de una primera sugerencia (por ejemplo, un rango de variable asumido incorrectamente, o una columna de identificador incluida por error en el modelo) fueron detectados y corregidos mediante esa verificación, no aceptados sin revisión.

Referencias

- IBM. (2017). *HR Analytics Employee Attrition & Performance* [Conjunto de datos]. Kaggle. https://www.kaggle.com/datasets/pavansubhasht/ibm-hr-analytics-attrition-dataset
- Parlamento Europeo y Consejo de la Unión Europea. (2016). *Reglamento (UE) 2016/679 relativo a la protección de las personas físicas en lo que respecta al tratamiento de datos personales (Reglamento general de protección de datos)*. Diario Oficial de la Unión Europea, L 119, 1-88. https://eur-lex.europa.eu/eli/reg/2016/679/oj/spa
- Congreso de la República de Colombia. (2012). *Ley Estatutaria 1581 de 2012, por la cual se dictan disposiciones generales para la protección de datos personales*. http://www.secretariasenado.gov.co/senado/basedoc/ley_1581_2012.html
- scikit-learn developers. (s. f.). *sklearn.metrics.silhouette_score*. https://scikit-learn.org/stable/modules/generated/sklearn.metrics.silhouette_score.html
- Guzmán Henao, J. A. (s. f.). *Guía de laboratorio · Semana 8 · Modelos supervisados y no supervisados* [Material de curso]. Broward International University. https://jhonyguzman72415.github.io/CIA6041_Clase_8/